Visione Artificiale per l'Automotive

1 20180227 – Lezione 01 - Intro

Corso con 9 lezioni teoriche e pratiche. Utilizzo di Ubuntu 16.04

Link alla home page del corso: http://www.ce.unipr.it/people/medici/teaching.php

User: `visione`

Password: `v2017`

Mail: medici@unipr.it

Libro on line: http://www.ce.unipr.it/people/medici/geometry/

Modalità d'esame:

- 20% esercitazioni di laboratorio
- 40% esame finale scritto, con domande a risposta aperta
- 40% progetto personale

Circa alla fine di maggio: un project report con presentazione del progetto che si intende svolgere.

90% degli incidenti automobilistici è dovuto a errore umano

Dati del 2013: circa 1,25 milioni di morti l'anno per incidenti automobilistici, 3700 in Italia; maggior numero nei paesi in via di sviluppo. I dati sono costanti nonostante i progressi tecnologici. Nel 93% dei casi gli incidenti sono dovuti ad errore umano.

Trasporto personale è dominante: 74% dei canadesi va in auto al lavoro, inquinamento causa il doppio dei morti degli incidenti.

Benefici di guida autonoma:

- meno stress
- mobilità per anziani e disabili
- meno inquinamento
- utilizzare in modo più produttivo il tempo oggi impiegato a guidare
- inoltre, un'auto rimane parcheggiata per il 95% del tempo, possibile car sharing.

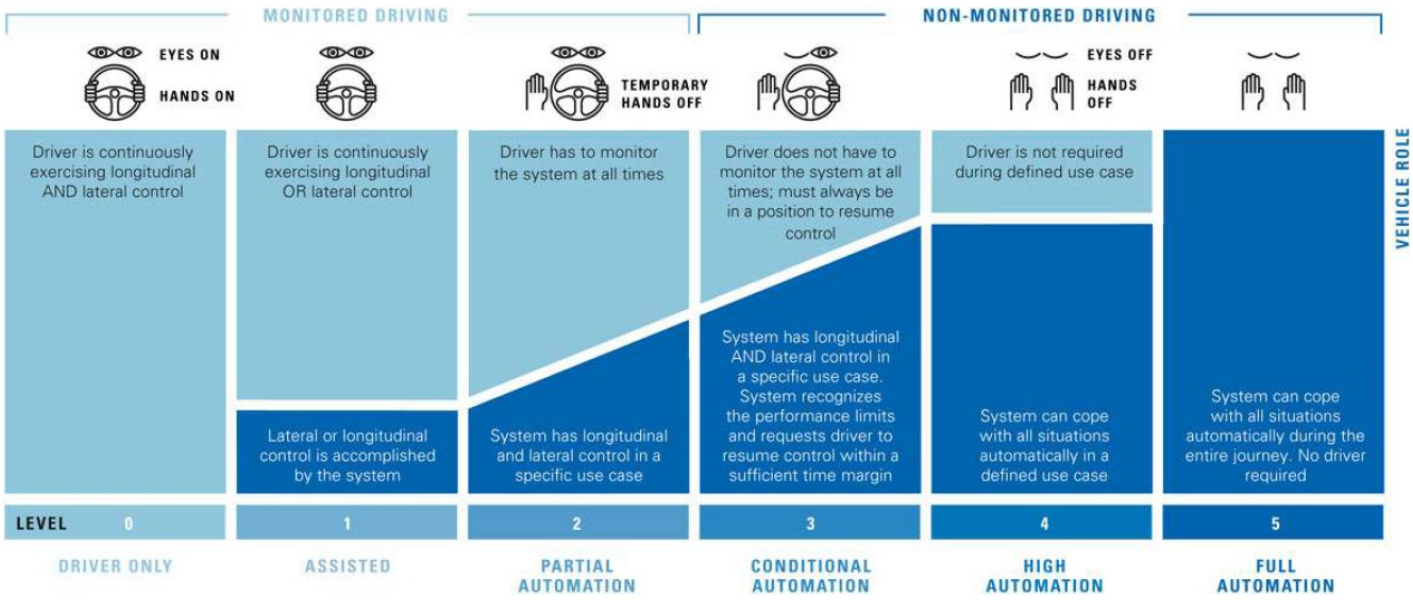
1.1 Storia del veicolo autonomo

- Nel **1939**, in pieno ottimismo post-bellico, si pensa a autostrade automatizzate e veicoli autonomi. Auto controllate via radio e la potenza viene da circuiti che sono parte dell'infrastruttura (la strada).
- Dopo gli anni '50 c'è perdita di interesse.
- Riappare nel **1982** con il telefilm Supercar
- **1986** first driving car on well-marked highways without traffic.
- Parma 1994
- 1998 Parma Argo, Lancia Thema
- 2004 Grand Challenge, nessun veicolo finisce, al massimo CMU percorre 11,78km
- 2005 Stanford vince con Stanley, 5 equipaggi finiscono la gara.
- 2007 Darpa Urban Challenge
- 2012 Google Self-driving car 300.000 miglia senza incidenti. Uso di laser scanner.
- Parma: 2009 Braive in Rome, VIAC 2010 15000km, 2013 Proud 15km nel centro di Parma.

Google self driving car, annunciata nel 2012: Velodyne scanner costo 100,000$, mappe dettagliate ed annotate.

Tesla Autopilot 2015

1.2 Livelli di autonomia



- **L0:** nessun livello di autonomia
- **L1**: Guidatore al comando, il sistema esercita il controllo laterale O longitudinale.
- **L2** guidatore al comando, il sistema controlla laterale E longitudinale in **specifici use-case** (es rischio tamponamento): il sistema sa quando deve agire (rischio tamponamento, distrazione del pilota, ecc.)
- **L3** sistema controlla laterale E longitudinale. **Il sistema sa quando deve disingaggiarsi** e lasciare il controllo al guidatore, avvisando per tempo.
- L4 il sistema controlla in specifici use case, in cui il guidatore non è richiesto
- **L5** il veicolo è totalmente autonomo.

Sfide e problemi

- Costi di ricerca e sviluppo di tali sistemi
- Problemi legislativi: di chi è la colpa in caso di incidente?
- Etici: il sistema deve prendere decisioni es su chi danneggiare in caso di pericolo
- Interazione con gli umani, inoltre: gli umani vorranno utilizzare questa tecnologia?

2 20180228 – Lezione 02 – Visual Perception

Diversi tipi di sensori sono disponibili ed utilizzati attualmente:

- Laser non funziona bene in ambienti polverosi, inoltre non funziona con la nebbia
- Radar ha range più elevato di laser, non influenzato dalla nebbia, ma individua solamente oggetti di metallo, no i pedoni.
- Telecamera: la telecamera a colori tende a produrre immagini leggermente sfocate in quanto

Un problema che deve essere considerato è quello della fault-tolerance del sistema

Problema dei sensori: i sensori è che vanno calibrati e sincronizzati. I sensori devono essere referenziati nello spazio e nel tempo.

Utilizzati Lidar e telecamere: il lidar costa troppo ed è un oggetto rotante, per cui non viene utilizzato dalle case automobilistiche per i veicoli in produzione.

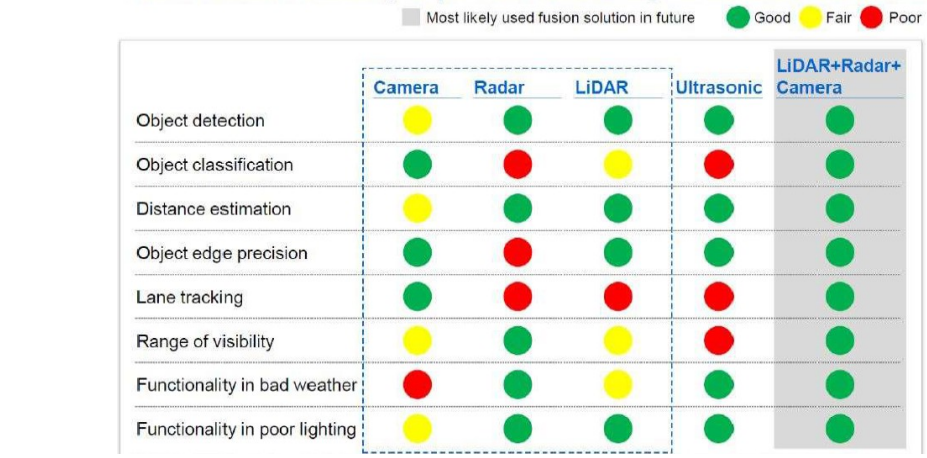
2.1 ADAS

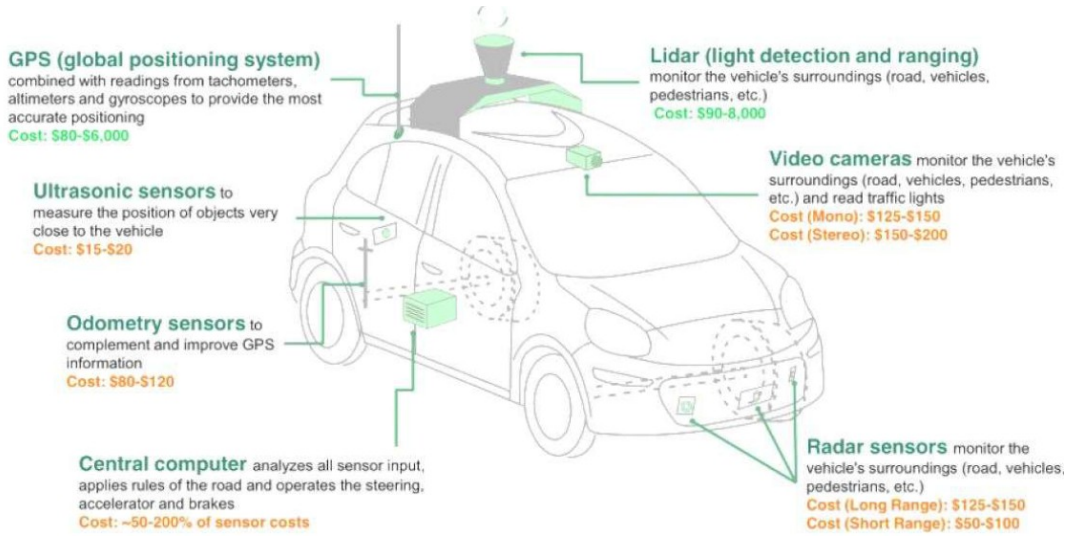
- Active Park assist
- Lane departure
- Traffic Sign detection

- Adaptive Cruise control (segue il veicolo davanti) / Stop and go
- Forward collision warning / braking system
- Blid spot detection
- Intelligent headlamp control
- Pedestrian detection

Per gli ADAS

L'unico modo di coprire le diverse esigenze è quello di utilizzare diversi sensori, ma poi si pone il problema della sensor fusion.





3 20180306 – Lezione 03 – Cameras, Datasets

In ambito automotive esiste lo standard AEC-Q100 che definisce i range di temperatura a cui possono operare i dispositivi: essi vanno da Grade 0 (-40°,+150°) a Grade 4 (0°,70°). A parte Grade 4, gli altri hanno minima temperatura di -40°. Il range di storage è ancora più ampio. Pochi sensori soddisfano questi requisiti.

Grade 0	-40°C	150° C
Grade 1	-40°C	125° C
Grade 2	-40°C	105° C
Grade 3	-40°C	85° C
Grade 4	0°C	70° C

Una camera deve essere almeno Grade 2 (-40°,+105°), in quanto tipicamente viene montata sul parabrezza, anche d'estate.

Altri requisiti su resistenza a shock meccanici e vibrazioni.

3.1 CCD / CMOS

CCD: più sensibile, ma affetto da optical blooming.

Optical blooming: luce intensa sporca tutta la colonna.

Il CMOS svuota ogni singolo pixel separatamente, non affetto da optical blooming

	CCD	CMOS
Optical blooming	**SI**	**NO**
Rumoroso?	**Meno**	**Di più,** causa presenza di maggiore circuiteria.

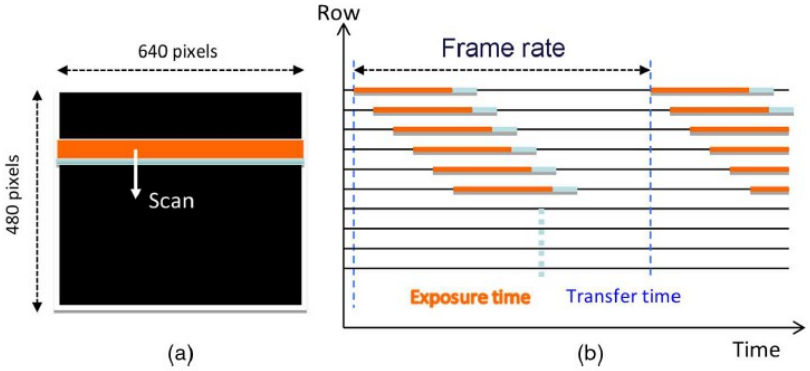
3.1.1 Rolling shutter / Global shutter

Mentre il circuito svota le cariche e trasferisce il frame acquisito, le celle sono ancora esposte alla luce. L'ultimo pixel trasferito rimane ancora esposto per tutto il tempo di trasferimento del frame, nell'ordine dei [ms].

Le macchine Reflex hanno uno shutter meccanico: su un veicolo non si può montare una camera con uno shutter meccanico con frequenza di 30Hz, si romperebbe dopo poco teempo di utilizzo.

L'effetto dell'otturatore viene ottenuto elettronicamente.

Rolling shutter: ogni riga dell'immagine viene acquisita in un tempo diversa dalle altre, e rimane esposta per un tempo aggiuntivo, pari al tempo necessario per trasferirla. Si noti inoltre che il Frame Rate è maggiore del transfer time.



Esempio:



Con Global shutter, tutti le righe hanno un comando comune di sample and hold.

L'effetto del rolling shutter si vede in particolare quando l'osservatore si muove o quando l'oggetto inquadrato ha una velocità comparabile con i tempi di acquisizione.

Per visione stereoscopica questo è un problema in quanto cerchiamo punti corrispondenti sulla stessa riga.

La riga viene prodotta da una lente distorcente che trasforma una retta in un arco, quindi essa viene acquisita in tempi diversi

Con il rolling shutter l'ottica distorce in modo differente tra la sinistra e la destra in quanto le due lenti sono leggermente diverse. Inolte le immagini sono acquisite a tempi diversi.

L'immagine deve essere prima rettificata da una warp table, per poi processare le immagini stereo.

Si calcola che, ad esempio, una warp table sposta in media un pixel in basso di 4 pixel(esempio). Quindi, il comando di scatto alle due camere viene dato in modo da compensare il tempo di acquisizione diverso, dato dal fatto che il pixel sarà acquisito in un tempo che non è quello nominale.

- $\frac{f}{lens\ aperture}$ = depth of field
- light = lens aperture = proportional to $\frac{1}{f^2}$
- shutter (exposure) time= the light acquired by each pixel is proportional to the shutter (exposure time).

Molta esposizione = molta luce ma immagine non nitida.

Lens aperture versus Depth of Field : maggiore apertura aumenta la luce ma diminuisce la Depth of Field.

In ambito automotive si vuole grande depth of field.

Nel sensore, un pixel ha una microlente che raccoglie la luce sulla parte attiva. Le microlenti al centro e ai lati del sensore ricevono la luce in modo diverso. Ai bordi l'immagine ha poca luce.

3.1.2 Pixel size (pitch size)

Un pixel ha una dimensione nell'ordine del [um]. Se un pixel è piccolo riceve poca luce.

Una Reflex ha pixel di 2oum. Attualmente siamo sui 1,62um.

640x480 aveva 6um.

(6 / 1,62) = circa 4 , che è il lato del pixel. Significa che l'area si è ridotta di 16 volte.

Aumentando il numero di pixel (la risoluzione), si ottiene che ogni singolo pixel riceve meno luce.

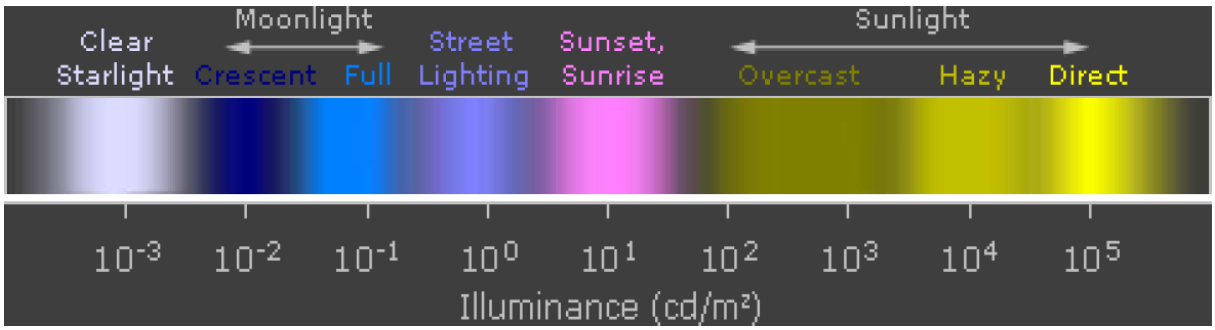
Il rumore deve essere minore del segnale che arriva al pixel.

3.1.3 Sensitivity/capacity

1 bit quanto campiona? Sotto il bit non c'è segnale. L'illuminazione che riceve un pixel, tra notte stellata e luce del sole diretta, varia di 10^8.

Dynamic Range

DR Tra luce del sole diretta e notte con luna piena => variazione di 10^6 => 120db (Dynamic Range)



$$DR = 20 * \log\left(\frac{N_{max}}{N_{dark}}\right)$$

Per codificare 10^5 avremmo bisogno di 17 bit => 32 bit per punto. Troppo utilizzo di memoria.

Quindi due possibilità:

- i bit vengono mappati in modo non lineare, oppure

- local mapping: nelle diverse aree si usano funzioni di mapping diverse.

Attualmente si usano 12 bit. A seconda del numero di bit dell'ADC possono essere coperti Dynamic Range diversi.

Numero di bit dell'ADC	Numero di livelli	Dynamic Range [dB]
8	256	48 dB
10	1024	60 dB
12	4096	72 dB

Siamo lontani dai 120 dB.

Diverse tecniche per mitigare la mancanza di una grande dinamica:

- HDR (High Dynamic Range) vengono prese diverse foto dello stesso soggetto a diverse esposizioni.
- WDR

Variazione Parametro	Effetto
Aumento dell'Apertura	Maggiore luce, ma minore profondità di campo.
Shutter (exposure time)	Maggiore luce, ma immagine meno nitida.
Capacity (aumento del numero di pixel del sensore)	Ogni singolo pixel ha meno area attiva, quindi riceve meno luce.

Range non dinamico : HDR e WDR (Wide Dynamic Range)

Windshield distortion: il parabrezza ha una distorsione non radiale che va in cascata con la distorsione della lente. E' in ogni caso possibile mettere l'ottica dietro il vetro, in quanto lo sporco del vetro è fuori dal depth of field.

3.1.4 Qualità dei sensori video

Vogliamo:sensitivity su grande spettro e Wide Dynamic Range. Inoltre operatività su range di temperature Grade 2.

Attenzione a thermal stability. Alluminio si dilata di 1 – 2 um/°C

I parametri di calibrazione quindi possono cambiare a causa della temperature.

Infine efficienza energetica: in particolare per le applicazioni in cui il dispositivo non è collegato alla rete elettrica (mobile / automotive / droni). Anche se è collegato alla rete elettrica, non si vuole incidere sul TCO (total cost of ownership) di chi ha comprato il dispositivo.

Alpha Go causa una bolletta di 3000$ per ogni partita. Alternativamente si può demandare ad un data center connesso in remoto, ma esso ha un costo.

4 20180306 – Lezione 05 – Sensor Calibration

In campo automotive per il 50% si usano camere pinhole e per il 50% camere fisheye.

Pinhole per vedere lontano, fisheye per vedere vicino in un ampia area.

Calibrare = individuare i valori dei parametri di un modello.

Il modello è quello della pinhole camera.

Per calibrare bisogna conoscere perfettamente la struttura del modello. Se la struttura del modello è corretta, allora saranno corrette le elaborazioni svolte a partire dal modello e quindi la fase di calibrazione sarà corretta.

La calibrazione individua il valore dei parametri fissi nella relazione che lega i punti dell'immagine con le rispettive coordinate nel mondo. Per individuare i parametri è possibile:

- Misurare i parametri della camera (metodo impreciso ed alcuni parametri possono non essere accessibili)
- Estrapolare i parametri mediante confronto con ground truth. Confrontare punti dell'immagine corrispondenti a punti del mondo a coordinate note. Il processo di calibrazione della camera richiede la conoscenza di alcuni vincoli: tali vincoli sono la corrispondenza tra punti dell'immagine e punti del mondo la cui posizione è nota.

Ad esempio, il laser scanner: con un laser scanner ad un piano non è possibile conoscere il pitch angle e la coordinata Z a cui si trova il sensore.

4.1 Parametri intrinseci ed estrinseci

Esistono parametri intrinseci ed estrinseci:

- parametri estrinseci si applicano a qualunque sensore:
  - traslazione (3 gradi di libertà)
  - rotazione (3 gradi di libertà)
- parametri intrinseci: dipendono dal tipo di sensore. Per la camera essi sono:
  - Focal length
  - principal point
  - Lens distortion

4.2 Coordinate Omogenee

Coordinate omogenee in 2D:

$$p=(u,v)\in R^2$$
$$\tilde{p}=(\tilde{u},\tilde{v},w)\ where\ w\neq 0$$
$$\tilde{p}=augmented\ vector$$
$$u=\frac{\tilde{u}}{w}$$
$$v=\frac{\tilde{v}}{w}$$

p può essere convertito in coordinate omogenee con w=1

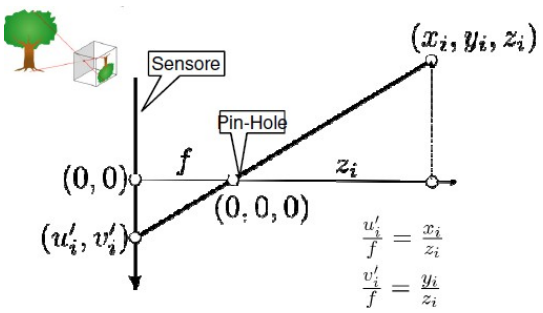
Coordinate omogenee in 3D

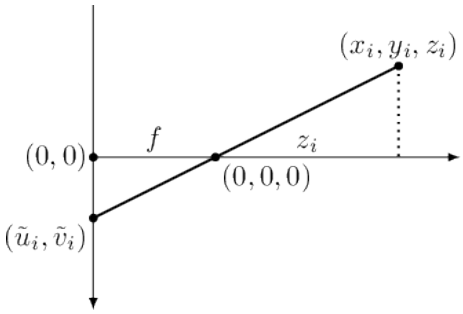
$$p=(x,y,z)\in R^3$$
$$\tilde{p}=(\tilde{x},\tilde{y},\tilde{z},w)$$
$$\tilde{p}=augmented\ vector$$
$$x=\frac{\tilde{x}}{w}\qquad y=\frac{\tilde{y}}{w}\qquad z=\frac{\tilde{z}}{w}$$

In coordinate omogenee due punti sono uguali se sono uguali una volta divisi per la propria coordinata **w**, es in 2D:

$$\tilde{p}=(\tilde{x},\tilde{y},w)\equiv w(\frac{\tilde{u}}{w},\frac{\tilde{v}}{w},1)\equiv p$$
$$\lambda_1(u,v,1)\equiv\lambda_2(u,v,1)$$

4.3 Pinhole Camera





(x_i, y_i, z_i) è espresso in coordinate camera (http://www.ce.unipr.it/people/medici/geometry/node134.html)

(u'_i, v'_i) è espresso in coordinate sensore. L'origine è nell'asse focale del sensore.

$$\frac{u'_i}{f} = \frac{x_i}{z_i} \qquad u_i = D_u u'_i + u_0 = D_u * f\frac{x_i}{z} + u_0 = k_u * \frac{x_i}{z_i} + u_o \;\rightarrow\; \tilde{u}_i = k_u * x_i + u_0 * z_i$$

$$\frac{v'_i}{f} = \frac{y_i}{z_i} \qquad v_i = D_v v'_i + v_0 = D_v * f\frac{y_i}{z} + v_0 = k_v * \frac{y_i}{z_i} + v_o \;\rightarrow\; \tilde{v}_i = k_v * y_i + v_0 * z_i$$

$$w = z_i$$

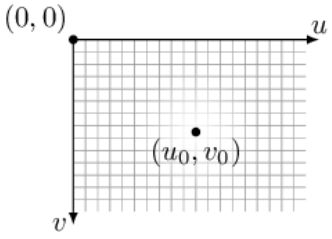
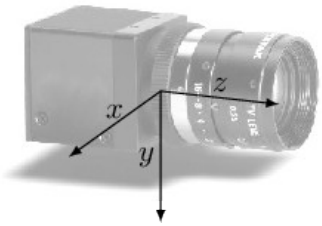
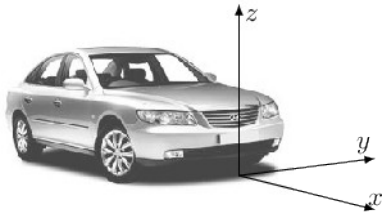
Coord. Omogenee: $\begin{pmatrix}\tilde{u}\\ \tilde{v}\\ w\end{pmatrix} = \begin{pmatrix}k_u & 0 & u_o\\ 0 & k_v & v_o\\ 0 & 0 & 1\end{pmatrix}\begin{pmatrix}x\\ y\\ z\end{pmatrix}$ Coord.immagine $\begin{pmatrix}u\\ v\\ 1\end{pmatrix} = \begin{pmatrix}k_u & 0 & u_o\\ 0 & k_v & v_o\\ 0 & 0 & 1\end{pmatrix}$

- (u,v) ≡ K(x,y,z)
- (u,v) ≡(f x/z + u0, f y/z + v0)
- (x,y,z) ≡ ((u – u0)/f, (v – v0)/f, 1)

K è la matrice dei parametri intrinseci della camera.

$$\mathbf{K} = \begin{bmatrix} k_u & k_\gamma & u_0 \\ 0 & k_v & v_0 \\ 0 & 0 & 1 \end{bmatrix}$$

$(u_{0,} v_0) = principal\ point$

Coordinate Immagine	Coordinate Camera	Coordinate veicolo
		

Le coordinate veicolo sono secondo standard **ISO 8855**, dette anche **Front-Left-Up (X=Front, Y=Left, Z=Up)**.

Esiste un sistema di coordinate Mondo , assoluto e fisso.

Esiste il sistema di coordinate veicolo; il veicolo è in movimento rispetto al mondo.

Esiste il sistema di coordinate del sensore , in generale distinto rispetto a quello della camera. Le coordinate della camera possono essere espresse in una terna non destrorsa.

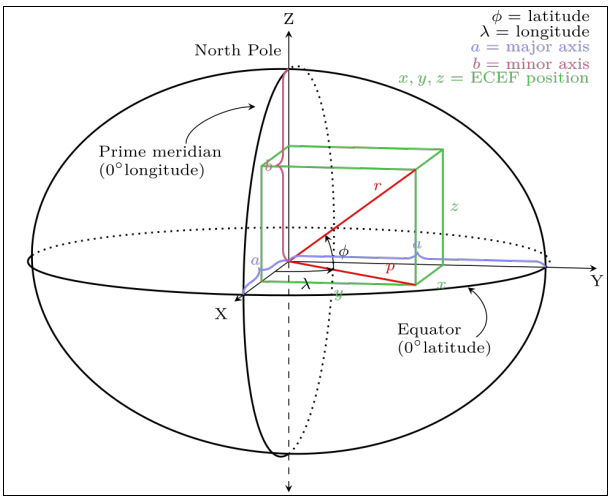
Quindi, le trasformazioni tra sistemi di riferimento sono:

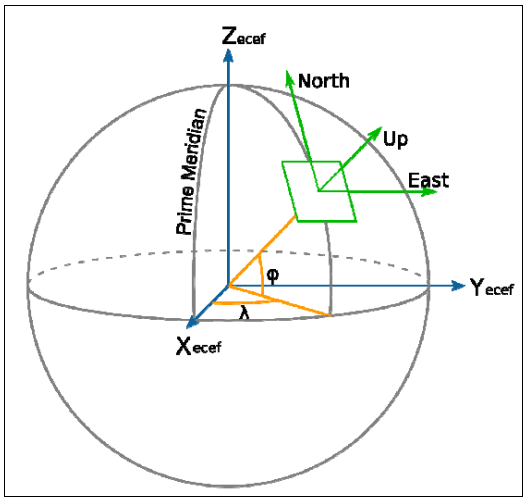
- Image – Camera
- Camera – Sensor
- Sensor – Vehicle
- Vehicle – World
- Local - Global

4.4 Sistemi di riferimento

4.4.1 Sistemi Globali

- **ECEF** (Earth Centered Earth-Fixed) . Centrato nel centro della terra ed in movimento solidale con essa.





- LLA (Longitude, Latitude, Altitude) : non è cartesiano

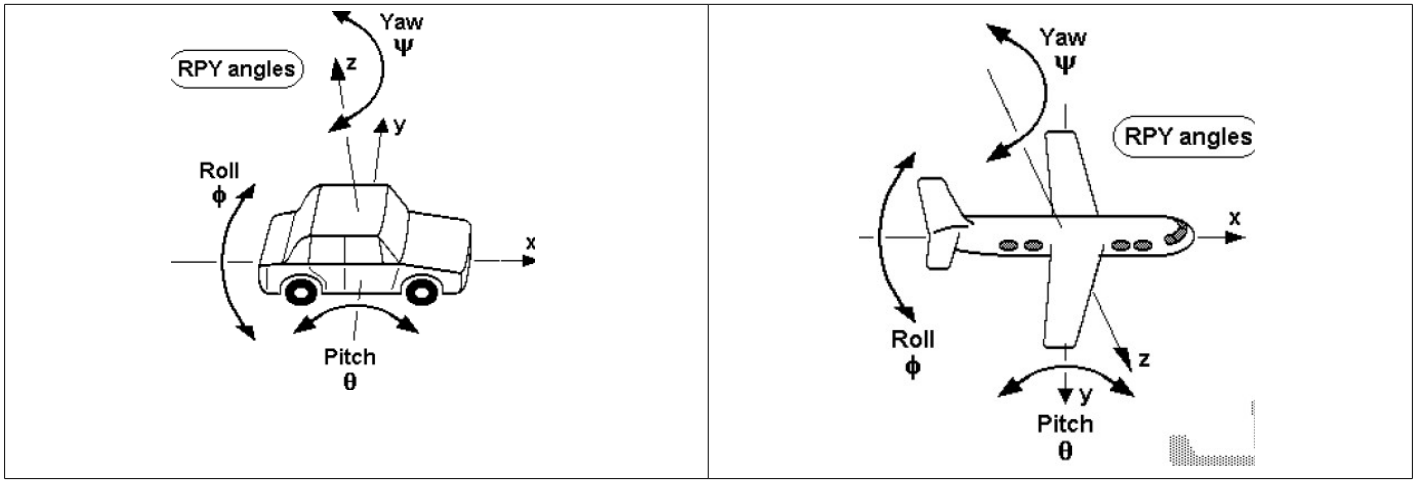
4.4.2 Sistemi World Locali “Lab”

- ENU (East North Up) : X=East Y=North Z=Up, usato da veicoli terrestri
- NED (North East Down) : X=North Y=East Z=Down, usato per i droni

Sistemi:

- C = camera
- S = sensor
- W = world

4.4.3 Sistemi di riferimento body, del veicolo



Roll , pitch yaw è la convenzione di Tait-Brian.

4.5 Parametri estrinseci

4.5.1 Matrici di rotazioni

Non esiste uno standard su come rappresentare le rotazioni. Esistono 2*12 combinazioni di parametri, inoltre le operazioni di rotazione non sono commutative. Inoltre: $R^{-1} \equiv {}^{T}R$

Da Sciavicco Siciliano: **R** esprime:

- gli assi della nuova terna = i versori della nuova terna rispetto al sistema di riferimento da cui si parte
- permette di esprimere lo stesso punto in due terne diverse
- la rotazione di un punto solidale alla terna

Notazione:

$\vec{p}_k = {}^K R_J * \vec{p}_j$: la matrice ${}^K R_J$ converte da sistema **K** a sistema **J**. (coerente con la notazione di Sciavicco Siciliano). Quindi ${}^K R_J$ contiene i versori del sistema di riferimento **J** espressi nel sistema di riferimento **K** .

$R \equiv {}^C R_W$ permette di convertire da World a Camera = esprime i versori del World in coordinate Camera.

Si vuole prendere un punto in coordinate World, moltiplicarlo per ${}^C R_W$ ed ottenere il corrispondente punto in coordinate camera. Quindi ${}^C R_W$ è la matrice dei versori del sistema di coordinate World espressi nel sistema di coordinate Camera.

Composizione di rotazioni : ${}^C R_W \equiv {}^C R_B * {}^B R_W$

Angoli di Roll, Pitch, Yaw (RPY), sono le rotazioni rispetto a X, Y, Z: Tait-Bryan.

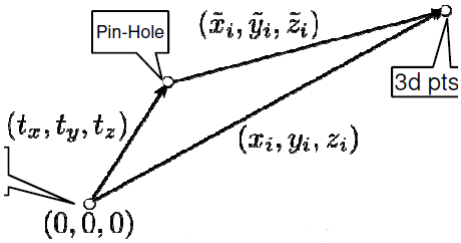
Π Permette di convertire da Sensor a World, visto che le coordinate camera sono riferita ad una terna non destrorsa

Una rotazione dipende da tre parametri.

Esiste anche la rappresentazione asse-angolo. L'asse è vettore unitario (2 degrees of freedom), angolo (one degree of freedom) => 3 degrees of freedom. Soffre di singolarità in (0,0,0).

Quaternione non soffre di singolarità : ha 4 parametri, ma solo 3 d.o.f.

4.5.2 Parametri Estrinseci



$\tilde{p}_C = punto\,espresso\ \text{in}\ coordinate\ camera$
$p = punto\,espresso\ \text{in}\ coordinate\ mondo$
$t = traslazione\,della\,camera\ \text{in}\ coordinate\ mondo$
$p_W = \tilde{p}_W + t_W \rightarrow \tilde{p}_W = p_W - t_W$
$R = converte\,da\,W\,a\,C \quad (R \equiv {}^C R_W), \quad quindi$
$\tilde{p}_C = R\,\tilde{p}_W = R(p_W - t_W) = R * p_W - R * t_W = R * p_W + \tilde{t}_0$
$Where: \tilde{t}_0 = -R * t_W$

4.5.3 Conversioni

$x_C = Coord\ camera$
$x_S = {}^S\Pi_C * x_C \qquad Coord\ sensore$
$x_B = {}^B R_S * x_S + t^{(B)} \qquad Coord\ Body$
$x_W = {}^W R_B * x_B + t^{(W)} \qquad Coord\ World$

4.5.4 Visual Odometry (VO)

Passaggio da coordinate World a Coordinate Immagine. Si usa la K.

$p^C = {}^C R_W (p^{(W)} - t^{(W)}) = {}^C R_W * p^{(W)} - {}^C R_W * t^{(W)} = {}^C R_W * p^{(W)} + \tilde{t}_0$ $\tilde{t}_0 = -{}^C R_W * t^{(W)}$ $p^C = [{}^C R_W \mid \tilde{t}_0] \begin{pmatrix} x_W \\ y_W \\ z_W \\ 1 \end{pmatrix}$ $\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = K * [{}^C R_W \mid \tilde{t}_0] \begin{pmatrix} x_W \\ y_W \\ z_W \\ 1 \end{pmatrix}$	$K = \begin{pmatrix} k_u & 0 & u_o \\ 0 & k_v & v_o \\ 0 & 0 & 1 \end{pmatrix}$ $P = K * [{}^C R_W \mid \tilde{t}_0]$

Visual Odometry: rilevare lo spostamento basandosi sulle immagini acquisite dalla telecamera. Utile in quanto ad esempio il GPS e l'inerziale non sono sincronizzati con la telecamera.

Abbiamo un punto noto in coordinate camera. Di tale punto in coordinate camera è nota la posizione e l'orientamento in due immagini successive. La camera ha una posa fissa rispetto al veicolo (la base).

Vogliamo ricavare qual'è stata la rotazione e la traslazione del veicolo tra la prima e la seconda immagine.

$p^1{}_{(C)} = R_{(C)} * p^0{}_{(C)} + t^{(C)}$ La rotazione R e la traslazione occorse in coordinate camera.

$t^{(B)} = {}^B R_C * t^{(C)}$

$R_{(B)} = {}^B R_C * R_{(C)}$

${}^1 R_0^{(B)} = {}^B R_C * R_{(C)}^0$

$t_{10}^{(B)} = {}^B R_C * t_0^{(C)}$

$x_1 = {}^1 R_0^{(B)} * x_0 + t_{10}^{(B)}$

$x_2 = {}^2 R_1^{(B)} * x_1 + t_{21}^{(B)} = {}^2 R_1^{(B)} * {}^1 R_0^{(B)} * x_0 + {}^2 R_1^{(B)} * t_{10}^{(B)} + t_{21}^{(B)}$

Il punto è fisso ed il veicolo si muove, per cui se vedo un punto muoversi e ruotare significa che il veicolo ha eseguito il movimento opposto.

5 20180313 Calibrazione implicita

5.1 Metodo Direct Linear Transformation (DLT)

Consideriamo la relazione: $P=[{}^{C}R_{W}|\tilde{t}_{0}]$ P è matrice 3x4 *che moltiplica* $\begin{pmatrix} x_W \\ y_W \\ z_W \\ 1 \end{pmatrix}$

P vale se l'immagine non è distorta.

Dobbiano passare da un sistema lineare ad uno non lineare. Tale sistema può essere risolto mediante il metodo di Newton (linearizzandolo localmente) ma in tale caso la soluzione di ferma in un minimo locale.

Esiste rumore nel passaggio dallo spazio mondo allo spazio immagine. Tale rumore non può essere considerato Gaussiano, ma ha media nulla.

$$(u,v)=f(x,y,z)+\varepsilon$$

Nella calibrazione dobbiamo determinare i valori della matrice P 3x4. Abbiamo come dati un insieme di punti 3D e rispettive proiezioni 2D.

$$\begin{pmatrix} u \\ v \end{pmatrix}=P*\begin{pmatrix} x_W \\ y_W \\ z_W \\ 1 \end{pmatrix} \quad \mathbf{P}=\begin{bmatrix} p_{11} & p_{12} & p_{13} & p_{14} \\ p_{21} & p_{22} & p_{23} & p_{24} \\ p_{31} & p_{32} & p_{33} & p_{34} \end{bmatrix}$$

$$u_i=\frac{p_{11}x_i+p_{12}y_i+p_{13}z_i+p_{14}}{p_{31}x_i+p_{32}y_i+p_{33}z_i+p_{34}}$$
$$v_i=\frac{p_{21}x_i+p_{22}y_i+p_{23}z_i+p_{24}}{p_{31}x_i+p_{32}y_i+p_{33}z_i+p_{34}}$$

$$p_{31}x_iu_i+p_{32}y_iu_i+p_{33}z_iu_i+p_{34}u_i-p_{11}x_i-p_{12}y_i-p_{13}z_i-p_{14}=0$$
$$p_{31}x_iv_i+p_{32}y_iv_i+p_{33}z_iv_i+p_{34}v_i-p_{21}x_i-p_{22}y_i-p_{23}z_i-p_{24}=0$$

Otteniamo un problema in 12 incognite e 2 equazioni. Può essere scritto nella forma:

$$L*p=0$$

- p contiene i parametri da determinare, quelli della matrice dei parametri intrinseci.
- L Contiene i vincoli e i valori x,y,z,u,v, con opportuni indici.

Presi 6 punti, otteniamo un sistema L*p = 0 che è un sistema omogeneo.

L'equazione `L*p = 0` vale a meno di un fattore moltiplicativo k. Infatti p risolve anche `k*L*p = 0`.

In cui `k` è uno scalare che moltiplica p. `p` è nota a meno di un fattore moltiplicativo, di conseguenza lo è anche P. La stessa equazione vale per tutti i punti che stanno su una retta e risultano proiettati negli stessi punti (u,v).

Questo metodo è puramente matematico, non considera focale, principal point, ecc.

Il metodo produce un sistema omogeneo di 12 incognite, ogni punto da 3D a 2D fornisce 2 vincoli. Sono necessari 6 punti non linearmente indipendenti per individuare una soluzione.

Tale sistema ha 12 incognite: 11 DOF se poniamo il vincolo di normalizzazione.

P trasforma un punto nel mondo in un punto nell'immagine. La matrice P non è unica. Dato un punto nell'immagine (u_i,v_i) , esistono infiniti punti nello spazio 3D che risultano proiettati nel punto (u_i,v_i) .

5.2 Omografia

5.2.1 Caso lineare

P permette di trasformare un punto mondo in un punto camera, ma la trasformazione non è invertibile.

Cosa succede se un punto appartiene ad un piano? Significa che abbiamo posto un vincolo

Es z=0

Otteniamo un'omografia: una trasformazione invertibile tra due spazi proiettivi: 3D nel piano z=0 <=> immagine

La matrice H permette di effettuare trasformazioni tra due immagini.

$$\begin{pmatrix} u' \\ v' \\ 1 \end{pmatrix} = \begin{pmatrix} h_0 & h_1 & h_2 \\ h_3 & h_4 & h_5 \\ h_6 & h_7 & h_8 \end{pmatrix} \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} \qquad H = \begin{pmatrix} h_0 & h_1 & h_2 \\ h_3 & h_4 & h_5 \\ h_6 & h_7 & h_8 \end{pmatrix}$$

Vedere la slide Omografia (3) . H definita da 9 parametri. Quindi in generale 9 degrees of freedom. Ogni punto fornisce 2 vincoli. Posso mettere un vincolo aggiuntivo e fissare 4 punti.

Tale vincolo può essere:

- $h_8 = 1$ ponendo questo vincolo posso avere che un altro coefficiente risulta nell'ordine di 10^6
- di normalizzazione $\|H\| = 1$. Tale vincolo viene soddisfatto da decomposizione QR o SVD.

Dati 4 vincoli la soluzione dell'omografia è unica a meno di multipli dati da un fattore moltiplicativo.

5.2.1.1 Come trovare la matrice H

Si usa un metodo tipo DLT (§5.1) Come input si hanno 4 punti in coordinate mondo (x_i,y_i,z_i) e 4 punti corrispondenti in coordinate immagine (u_i,v_i) (Nota: coordinate immagine, non camera). I punti in coordinate mondo sono sul piano z=0

$$\begin{pmatrix} \tilde{u}_i \\ \tilde{v}_i \\ w_i \end{pmatrix} = \begin{pmatrix} h_0 & h_1 & h_2 \\ h_3 & h_4 & h_5 \\ h_6 & h_7 & h_8 \end{pmatrix} \begin{pmatrix} x_i \\ y_i \\ 1 \end{pmatrix}$$

$$u_i = \frac{\tilde{u}_i}{w_i} = \frac{h_0 * x_i + h_1 * y_i + h_2}{h_6 * x_7 + h_7 * y_i + h_8}$$

$$v_i = \frac{\tilde{v}_i}{w_i} = \frac{h_3 * x_i + h_4 * y_i + h_5}{h_6 * x_7 + h_7 * y_i + h_8}$$

$$h_0 * x_i + h_1 * y_i + h_2 - u_i * h_6 * x_7 - u_i * h_7 * y_i - u_i * h_8 = 0$$

$$h_3 * x_i + h_4 * y_i + h_5 - v_i * h_6 * x_7 - v_i * h_7 * y_i - v_i * h_8 = 0$$

$$x_i * h_0 + y_i * h_1 + h_2 - u_i * x_7 * h_6 - u_i * y_i * h_7 - u_i * h_8 = 0$$

$$x_i * h_3 + y_i * h_4 + h_5 - v_i * x_7 * h_6 - v_i * y_i * h_7 - v_i * h_8 = 0$$

u_i,v_i,x_i,y_i sono i valori noti; h_i sono le incognite.

$$\begin{pmatrix} x_1 & y_1 & +1 & 0 & 0 & 0 & -u_1 * x_1 & -u_1 * y_1 & -u_1 \\ 0 & 0 & 0 & x_1 & y_1 & +1 & -v_1 * x_1 & -v_1 * y_1 & -v_1 \\ x_2 & y_2 & +1 & 0 & 0 & 0 & -u_2 * x_2 & -u_2 * y_2 & -u_2 \\ 0 & 0 & 0 & x_2 & y_2 & +1 & -v_2 * x_2 & -v_2 * y_2 & -v_2 \\ x_3 & y_3 & +1 & 0 & 0 & 0 & -u_3 * x_3 & -u_3 * y_3 & -u_3 \\ 0 & 0 & 0 & x_3 & y_3 & +1 & -v_3 * x_3 & -v_3 * y_3 & -v_3 \\ x_4 & y_4 & +1 & 0 & 0 & 0 & -u_4 * x_4 & -u_4 * y_4 & -u_4 \\ 0 & 0 & 0 & x_4 & y_4 & +1 & -v_4 * x_4 & -v_4 * y_4 & -v_4 \end{pmatrix} \begin{pmatrix} h_0 \\ h_1 \\ h_2 \\ h_3 \\ h_4 \\ h_5 \\ h_6 \\ h_7 \\ h_8 \end{pmatrix} = 0$$

Per la soluzione vedere §5.2.2.

5.2.2 Soluzione di un sistema lineare omogeneo

Si noti che, dato un sistema lineare omogeneo $A*x=0$, un risolutore lineare trova una soluzione che soddisfa:

- $min\|A*x\|^2$
- nell'ambito del vincolo $\|x\|^2=1$

Da (http://www.ce.unipr.it/~medici/geometry/node2.html)

Un sistema lineare omogeneo ha forma: $\mathbf{Ax} = 0$, in cui x=0 è una soluzione ovvia.

E' necessario trovare un sottospazio vettoriale che soddisfa Ax=0, ovvero un nucleo (kernel) di A. Il nucleo è un insieme di punti che vengono annullati dalla funzione.

Per ottenere una soluzione unica bisogna aggiungere un ulteriore vincolo, es: |x|=1 .

Si utilizza la decomposizione SVD : A = U*S*V. le basi del kernel di A sono le colonne di V associate agli autovalori nulli della matrice diagonale S. In genere, a causa della presenza di rumore, non esisterà un valore singolare esattamente nullo ma deve essere scelta la colonna associata al minimo valore singolare.

Gli autovettori associati a valori singolari nulli della matrice **S** rappresentano pertanto il kernel della matrice stessa e il numero di autovalori nulli rappresenta la dimensione del kernel stesso.

5.2.3 Caso non lineare

Supponiamo di prendere un numero di punti superiore a 4. Otteniamo un sistema sovradimensionato.

Le misure sono affette da rumore.

$$(u_i, v_i)=h(x_i, y_i)+\vec{\varepsilon}$$

In generale, abbiamo un sistema in cui ci sono dei parametri che dobbiamo stimare. Tali parametri sono β

$$(u_i, v_i)=f_\beta(x_i, y_i, z_i)+\vec{\varepsilon}$$

Se il rumore è gaussiano (non è vero, ma almeno ha media nulla), calcoliamo il residuo come:

$$\vec{r}=(u_i, v_i)-f(x_i, y_i, z_i)$$

$S=r^T*r=\|r\|^2$ S è il residuo tra il punto stimato e quello osservato, è distanza euclidea.

β deve minimizzare S nei punti osservati.

5.2.4 Inverse Perspective mapping

$$\begin{pmatrix}u\\v\\1\end{pmatrix}=KR\left(\begin{pmatrix}x\\y\\0\end{pmatrix}-\begin{pmatrix}x_0\\y_0\\z_0\end{pmatrix}\right) \qquad t=\begin{pmatrix}x_0\\y_0\\z_0\end{pmatrix}$$

Possiamo riscriverla come $\begin{pmatrix}u\\v\\1\end{pmatrix}=KR_Z\begin{pmatrix}x\\y\\1\end{pmatrix}=H\begin{pmatrix}x\\y\\1\end{pmatrix}$

Se conosciamo K, R, t => possiamo ottenere H.

Se conosciamo punti nel mondo e corrispondenti nell'immagine possiamo ottenere H.

Data l'equazione omografica del piano è possibile conoscere la posizione della camera

H ha nove parametri, ha 8 gradi di libertà con vincolo di normalizzazione.

Possiamo utilizzarla per trovare le linee della carreggiata.

5.2.5 Camera virtuale

$$\begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = \mathbf{K_1 R_1} \begin{pmatrix} x \\ y \\ z \end{pmatrix} \quad \text{Camera 1}$$

$$\begin{pmatrix} u_2 \\ v_2 \\ 1 \end{pmatrix} = \mathbf{K_2 R_2} \begin{pmatrix} x \\ y \\ z \end{pmatrix} \quad \text{Camera 2}$$

$$\begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = \underbrace{\mathbf{K_1 R_1 R_2^{-1} K_2^{-1}}}_{\text{H}} \begin{pmatrix} u_2 \\ v_2 \\ 1 \end{pmatrix}$$

- Conoscendo i parametri delle due camere è possibile trasformare una camera nell'altra.
- Conoscendo H è possibile ricavare i parametri relativi tra le due immagini.

5.3 Calibrazione esplicita

Abbiamo residuo che vogliamo minimizzare tramite i parametri beta:

$$S = \sum_i \left| (u_i, v_i) - f_\beta (x_i, y_i, z_i) \right|^2$$

Se non abbiamo un modello pinhole, ma la lente è affetta da distorsione radiale:

$$(u_i, v_i) = K * f_d \left(R * \begin{pmatrix} x \\ y \\ z \end{pmatrix} + t \right)$$

Abbiamo un certo numero di parametri da stimare, dati da K (3), R (9), t (3)

5.4 Autocalibrazione monoculare

Se non conosciamo le dimensioni di qualche elemento dell'immagine allora non possiamo calibrare.

5.4.1 Ambiente strutturato

$$R = \begin{pmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \end{pmatrix}$$

$$u_i = \frac{r_{11} * x_i + r_{12} * y_i + r_{13} * z_i + t_x}{r_{31} * x_i + r_{32} * y_i + r_{33} * z_i + t_z} \qquad \lim_{x \to \infty} u_i(x, y, z) = \frac{r_{11}}{r_{31}}$$

$$v_i = \frac{r_{21} * x_i + r_{22} * y_i + r_{23} * z_i + t_y}{r_{31} * x_i + r_{32} * y_i + r_{33} * z_i + t_z} \qquad \lim_{x \to \infty} v_i(x, y, z) = \frac{r_{21}}{r_{31}}$$

$$\lim_{y \to \infty} (\tilde{u}_i, \tilde{v}_i) = \left(\frac{r_{12}}{r_{32}}, \frac{r_{22}}{r_{32}} \right)$$

$$\lim_{z \to \infty} (\tilde{u}_i, \tilde{v}_i) = \left(\frac{r_{13}}{r_{33}}, \frac{r_{23}}{r_{33}} \right)$$

Per determinare 3 angoli bastano due punti di fuga.

Una volta determinato il punto di fuga per x => infinito:

$$\lim_{x\to\infty} u_i(x,y,z) = \frac{r_{11}}{r_{31}} \;\rightarrow\; u_i = \frac{r_{11}}{r_{31}}$$

$$\lim_{x\to\infty} v_i(x,y,z) = \frac{r_{21}}{r_{31}} \;\rightarrow\; v_i = \frac{r_{21}}{r_{31}}$$

$r_{11}^2 + r_{21}^2 + r_{31}^2 = 1$

$r_{11} = u_i * r_{31} \;\rightarrow\; r_{11}^2 = u_i^2 * r_{31}^2$

$r_{21} = v_i * r_{31} \;\rightarrow\; r_{21}^2 = v_i^2 * r_{31}^2$

$r_{11}^2 + r_{21}^2 + r_{31}^2 = 1 \;\rightarrow\; u_i^2 * r_{31}^2 + v_i^2 * r_{31}^2 + r_{31}^2 = 1 \;\rightarrow\; r_{31}^2(u_i^2 + v_i^2 + 1) = 1 \;\rightarrow\; r_{31} = \frac{1}{\sqrt{u_i^2 + v_i^2 + 1}}$

$r_{11} = u_i * r_{31}$

$r_{21} = v_i * r_{31}$

Con due punti di fuga possiamo ottenere due colonne di R.

La terza colonna può essere ottenuta per il vincolo di ortonormalità.

6 20180314 – Slide 06 – Odometry and reconstruction

- Ricostruzione 3D
- Struttura dal moto
- Visual Odometry (VO): stima del moto di una camera in real time utilizzando una sequenza di immagini (egomotion)
- Bundle reconstruction: tutto fatto in un unico colpo

Odometry: dal greco, misura della rotta = stima di come cambia la posizione nel tempo.

VO inventata nel 1980 da Moraveck, utilizzata dalla NASA per sonde spaziali in quanto su terreni accidentati è più precisa dell'odometro alla ruota, che slitta su terreni accidentati.

Spirit e Opportunity (2004) usano visual odometry. 2004: Nister paper su VO.

VO, utilizzando Kalman, può fondere altre tecnologie come il laser e l'odometro alla ruota. Kalman dà più o meno peso ad una misura rispetto ad un altra.

Il GPS non è utilizzabile in ambiente indoor, ad esempio per i droni, inoltre il GPS ha un errore locale, indipendente dal tempo e dalla lunghezza che è stata percorsa. VO è imprecisa nel lungo periodo perchè integra gli spostamenti successivi ed accumula errore, mentre per il GPS l'errore è indipendente dal tempo.

6.1 Stereovisione

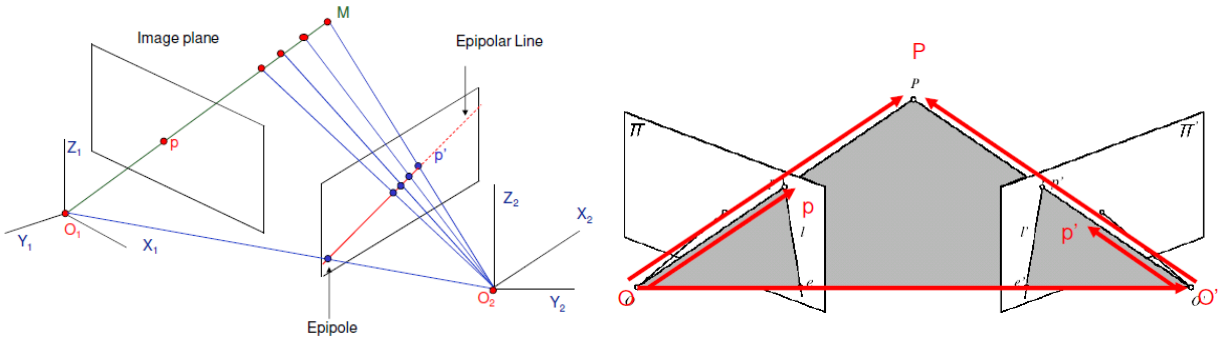
KeyPoint = uno stesso punto nello spazio, identificato in più immagini prese contemporaneamente da camere diverse.

Cosa si può estrarre dalla conscenza di corrispondenze tra punti immagine (Keypoint)?

- Ricorstruzione tridimensionale della scena con coppia di camere
- Ricostruzione 3D con una sola camera che si sposta nel mondo
- Capire di quanto si sono mosse le camere in un sistema stereo.

Rettificazione: la rettificazione semplifica il problema. Dato un punto, il punto corrispondente nell'altra camera ha la stessa coordinate verticale. Se non è possibile rettificare?

Quando non è possibile rettificare? Esempio: se l'immagine è inquadrata da camere che sono molto distanti e orientate diversamente, se rettifico mi perdo molta parte delle immagini.



Un punto **p** in un immagine sottende una retta nello spazio, passante per il punto focale. Nell'altra immagine tale retta diventa una retta epipolare. La proiezione del pinhole ($\mathbf{O_1}$) sull'altra immagine (**immagine 2**), si chiama epipolo. Tale epipolo può anche essere al di fuori dell'immagine 2, ma in esso si incontrano tutte le rette epipolari. $\mathbf{O_1}$ viene anche chiamato centro ottico.

Quanto detto vale anche se si scambiano tra loro le camere 1 e 2.

I centri ottici $\mathbf{O_1}$ e $\mathbf{O_2}$, i punti immagine p e p', ed il punto P, sono sullo stesso piano.

Sono complanari i vettori, per cui : $\vec{Op}\cdot[\vec{OO'}\,x\,\vec{O'p'}]=0$

6.1.1 Pinhole camera

Equazione della pinhole camera: $(u_i, v_i) = K[R\tilde{t_0}] * \begin{pmatrix} x_i \\ y_i \\ z_i \\ 1 \end{pmatrix}$ con $p_i = (u_i, v_i)$ in coordinate immagine.

$p_i \equiv K * m_i$ $\quad m_i = R(x_i - t_0)$ $\quad m_i$ Coordinate camera normalizzate

6.1.2 Forma matriciale del prodotto vettoriale

$$\vec{a} \times \vec{b} = [a]_x * \vec{b} \text{ where}$$

$\vec{c} = \vec{a} \times \vec{b}$ Per costruzione $\vec{c}$ è ortogonale ad **a** e **b**. $[a]_x = \begin{bmatrix} 0 & -a_z & a_y \\ a_z & 0 & -a_x \\ -a_y & a_x & 0 \end{bmatrix}$ $\vec{a} \cdot \vec{c} = 0$ e $\vec{b} \cdot \vec{c} = 0$

$[a]_x$ è matrice antisimmetrica.

6.1.3 Matrice essenziale E

La matrice essenziale associa tra loro le coordinate camera. X è un punto in coordinate mondo.

$$\mathbf{m}_1 = \mathbf{R}_1(\mathbf{x} - \mathbf{t}_1) \qquad \mathbf{m}_2 = \mathbf{R}_2\mathbf{R}_1^{-1}\mathbf{m}_1 + \mathbf{R}_2(\mathbf{t}_1 - \mathbf{t}_2)$$
$$\mathbf{m}_2 = \mathbf{R}_2(\mathbf{x} - \mathbf{t}_2) \qquad \mathbf{m}_2 = \mathbf{R}\mathbf{m}_1 + \mathrm{t}$$

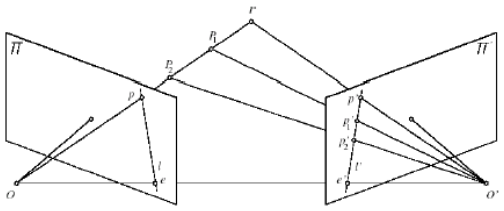
$$\mathbf{m}_2^{\mathsf{T}}(\mathrm{t} \times \mathbf{m}_2) = \mathbf{m}_2^{\mathsf{T}}(\mathrm{t} \times \mathbf{R}\mathbf{m}_1) + \mathbf{m}_2^{\mathsf{T}}(\mathrm{t} \times \mathrm{t})$$
$$= 0 \qquad = 0$$

$$\mathbf{m}_2^{\mathsf{T}}(\mathrm{t} \times \mathbf{R}\mathbf{m}_1) = 0$$

$$\mathbf{m}_2^{\mathsf{T}}([\mathrm{t}]_x \mathbf{R})\mathbf{m}_1 = 0 \qquad \mathbf{m}_2^{\mathsf{T}}\mathbf{E}\mathbf{m}_1 = 0$$

Se m_1 e m_2 sono punti omologhi, soddisfano $m_2^T([t]_x R) m_1 = 0$

$E = [t]_x R$



$$\vec{a} \times \vec{b} = [a_x]\vec{b}$$

Otteniamo una relazione che lega i punti omologhi in **coordinate camera**.

La matrice essenziale deriva dalla posizione relativa delle due camere. Dati due punti in coordinate immagine, posso testare se essi sono omologhi.

La matrice E si basa su posizione relativa, non su parametri intrinseci. Non considera le coordinate camera (u,v). La matrice E è definita a meno di un fattore di scala (**kE**).

La matrice ha 5 gradi di libertà: yaw, pitch, roll relativi e la direzione tra i due pin-hole (3 gradi di libertà, ma normalizzando ne bastano 2) => **5 gradi di libertà**.

E può essere ricavata sulla base di 5 punti (non lineare) o di 8 punti (lineare).

E dipende dai parametri estrinseci relativi, infine è di rango 2 (ha determinante nullo e rango 2).

$E = [t]_x R$: la matrice R è ben definita. $[t]_x$: antisimmetrica e definita a meno di un fattore moltiplicativo.

Se per caso conosciamo E ed R, possiamo determinare $[t]_x$. La matrice E serve per sapere se due punti sono omologhi.

6.1.4 Retta in coordinate implicite.

$a\,x+by+c=0$ Retta in coordinate implicite.

$p=(x\,,\,y\,,1)^T$

$l=(a\,,b\,,c)^T$ (p è un punto in coordinate immagine).

La retta può essere scritta come $l\cdot p=0 \quad l^T p=p^T l=0$

$m_1{}^T E\,m_2=0 \quad se\ p=m_1$ e $l=Em_2 \rightarrow m_1{}^T E\,m_2=0$ è l'equazione di una retta.

$se\ p=m_1$ e $l=Em_2 \rightarrow p^T * l=0$ definisce il luogo dei punti in cui m_2 può cadere in immagine 1.

Definisce la retta epipolare vista dall'immagine 1, derivante dalla scelta di m_2 nell'immagine 2.

Invertendo i ruoli: $m_2{}^T E\,m_1=0 \quad se\ p=m_2$ e $l=Em_1$

p è verificata per i punti di immagine 2 che possono essere omologhi di m_1

6.1.5 Matrice essenziale F

Se non si conoscono i parametri intrinseci, si può utilizzare F, che lega punti omologhi in coordinate omogenee immagine: $p_2{}^T * F * p_1=0$, dove $F=K_2{}^{-T} E\,K_1{}^{-T}$ e $p=Km$.

Valgono le stesse relazioni: $l_1=F^T p_2$

$p_2{}^T l_1$ where $l_1=F*p_1$ Nella relazione, i punti p sono espressi in coordinate immagine.

$p_1{}^T l_2$ where $l_2=F^T p_2$

F è matrice 3x3, singolare di rango 2. Teoricamente F avrebbe 11 gradi di libertà:

- 3 dovuti a K1
- 5 dovuti ad E
- 3 dovuti a K2

In realtà i gradi di libertà sono solamente 7. F formata da 7 parametri efficaci, i quali non hanno nessun significato fisico.

Partendo da F non possiamo sapere i parametri che l'hanno generata. Se anche K1=K2, avremmo comunque 8 parametri teorici.

Può essere stimata da 7 corrispondenze in modo non lineare e da 8 corrispondenze in modo lineare.

Gli epipoli soddisfano il vincolo:

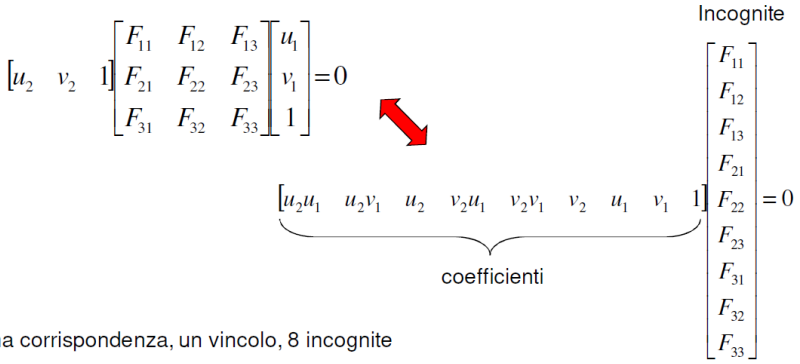
- In immagine 1 : $F*e_1=0$
- In immagine 2 : $F^T * e_2=0$

Tutte le rette epipolari passano per l'epipolo corrispondente.

Esempio: sono in immagine 1, fisso un punto nell'immagine ed esso definisce una retta in immagine 2. I punti in immagine 2 che soddisfano la retta sono tali per cui : $p^T * F * p_1=0$ se però il punto nell'immgine 1 è l'epipolo, allora dato un qualunque punto nell'immagine 2, esso giace su una retta che passa per l'epipolo, per definizione. Per verificare l'equazione si deve avere che :

$$F*e_1=0 \quad \text{, in tal modo :} \quad \forall\, p\in Image_2 \rightarrow p^T * F * e_1=0$$

6.1.6 8 point algorithm per matrice F



Una corrispondenza, un vincolo, 8 incognite

Inoltre, la matrice deve soddisfare il vincolo $||F|| = 1$, che è un vincolo.

Servono 8 punti . Dal punto di vista Bayesiano non va bene in quanto ci sono delle variabili che sono note a meno di rumore, ma tali coefficienti vengono moltiplicati tra loro.

Lo stimatore non è ottimo. Il rumore sui punti viene trasformato nei parametri in modo non lineare, in quanto le coordinate sono moltiplicate tra di loro.

L' 8 point algorithm produce un sistema omogeneo in 8 incognite, che può anche essere sovradimensionato.

8 point algorithm produce una matrice mal condizionata. Pertanto funziona male con il metodo dei minimi quadrati.

Vedere l'algoritmo RANSAC.

Esempi nelle slide 26-31. Posso mappare immagini prese con camere differenti e da punti di vista diversi, purchè sia in grado di associare i punti, ad esempio a mano. Questo mi permette di ottenere F o E.

Algoritmo 8 punti normalizzato. Per migliorare la performance del metodo dei minimi quadreati, posso normalizzare l'immagine in coordinate [-1;+1]x[-1;+1]. Quindi normalizzo i punti dell'immagine.

6.1.7 Calcolo della matrice F

Per il calcolo della matrice F, che ha 7 gradi di libertà come matrice affine, possiamo utilizzare:

- metodo degli 8 punti : un metodo lineare che ottimizza una quantità algebrica. La matrice era algebrica.
- Esistono metodi che usano 7 o 5 punti, non lineari
- troviamo la matrice che è più vicina ad F secondo la decomposizione SVD

Le tecniche per trovare F sono:

- metodo degli 8 punti
- netodo dei 7 punti
- infinite tecniche che utilizzano 5 punti.

6.1.8 Stime non lineari di F

Le stime non lineari di F ottimizzano una matrice geometrica, è meglio dal punto di vista del rumore.

In coordinate esatte: $\hat{p}_2 F \hat{p}_1 = 0$ in coordinate non affette da rumore.

$p_1 = \hat{p}_1 + \epsilon_1$
$p_2 = \hat{p}_2 + \epsilon_2$ p_1 e p_2 sono affetti da rumore.

Il rumore è rumore gaussiano e rumore di quantizzazione (quindi p è espresso in coordinate immagine)

Se moltiplico per 2 avrò un residuo doppio. Il residuo di $\hat{p}_2 F \hat{p}_1$ non ha significato, è un numero puro che non ha significato.

Passiamo ora in coordinate affette da rumore e calcoliamo il residuo in queste coordinate $p_2 F p_1$

Il residuo serve per: trovare punti omologhi, eseguire ottimizzazione non lineare e trovare la stima migliore di F.

6.1.9 Symmetric Transfer Error (STE)

$$\min_{\mathbf{F}} \sum_i \left(d\left(\mathbf{m}_{1,i}, \mathbf{F}\mathbf{m}_{2,i}\right)^2 + d\left(\mathbf{m}_{2,i}, \mathbf{F}^\top \mathbf{m}_{1,i}\right)^2 \right)$$

$d(p,l)$ distanza punto-retta



Symmetric transfer error (STE): trovo la F per la quale ho la minima distanza punto-retta per i punti dati. Uso la distanza come funzione obbiettivo da minimizzare in F. Di tale funzione posso anche fare la derivata.

STE: p2 è rumorosa. Viene moltiplicata . La funzione obbiettivo dipende dai punti e dalle incognite che sto cercando. E' un metodo sub-ottimo dal punto di vista Bayesiano.

6.1.10 Maximum Likelihood estimation (MLE)

- *MLE*

$$\min_{\mathbf{F}} \sum \left\|\mathbf{m}_{1,i} - \hat{\mathbf{m}}_{1,i}\right\|^2 + \left\|\mathbf{m}_{2,i} - \hat{\mathbf{m}}_{2,i}\right\|^2$$

sotto il vincolo $\hat{\mathbf{m}}_{2,i}^\top \mathbf{F} \hat{\mathbf{m}}_{1,i} = 0$

- Ma come fare a calcolare i punti $\mathbf{m}_1$ e $\mathbf{m}_2$?
- Si trasforma in un problema di triangolazione *virtuale*.

$\hat{\mathbf{m}}_1 = \hat{\mathbf{x}}$ $\quad \hat{\mathbf{m}}_2 = \mathbf{P}\hat{\mathbf{x}}$

6.1.11 Applicazioni delle Matrici essenziale (E) e Fondamentale (F)

- Sono entrambe matrici 3x3
- E lavora in coordinate camera, richiede la calibrazione, è scomponibile in R e t
- F lavora in coordinate immagine, non richiede la calibrazione.

6.1.12 Pose recovery a partire da matrice essenziale (E).

$E = \hat{T} * R$ dove $\hat{T} = t_x$

Mediante decomposizione SVD si può decomporre E in $U \Sigma V^T$, dove:

- U e V sono matrici ortogonali,
- Σ è una matrice diagonale che contiene gli autovalori di E.

Siccome E è una matrice singolare, allora ha un autovalore zero. Se sostituisco Σ con una matrice diagonale in cui un valore è zero, ottengo la matrice più simile a quella data, proiettata nello spazio delle matrici essenziali.

Prendo ad esempio come diagonale $\Sigma = Diag(1,1,0)$

6.1.13 Da S.Soatto (2002)

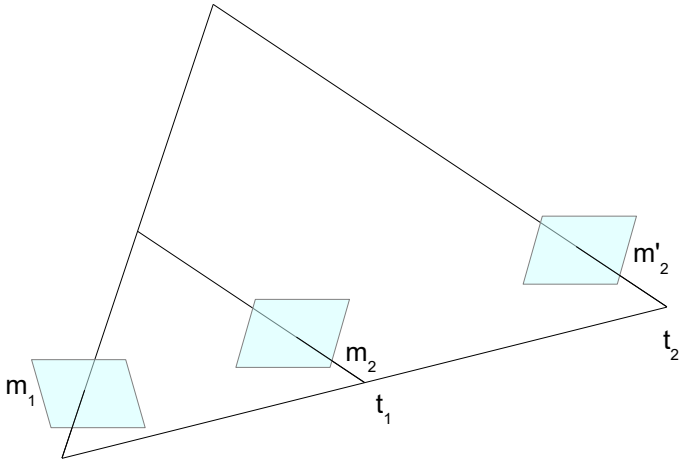
Date due viste della stessa scena, scoprire lo spiazzamento della camera e la struttura 3D.

Una matrice non nulla è essenziale E , se e solo se:

- Decomponibile (decomposizione a valori singolari) SVD come $E = U \Sigma V^T$, in cui $\Sigma = Diag(\sigma_1, \sigma_2, \sigma_3)$, con un autovalore nullo e due non nulli.
- U e V . sono due matrici di rotazione SO(3).

La matrice $E = \hat{T} * R$ ha 5 gradi di libertà:

- 3 dati dalla rotazione
- 2 dati da t, la translazione è nota a meno di un fattore di scala, infatti camere orientate nello stesso modo, ma a traslazioni diverse, fanno in modo che ci sia ugualmente corrispondenza tra i punti.



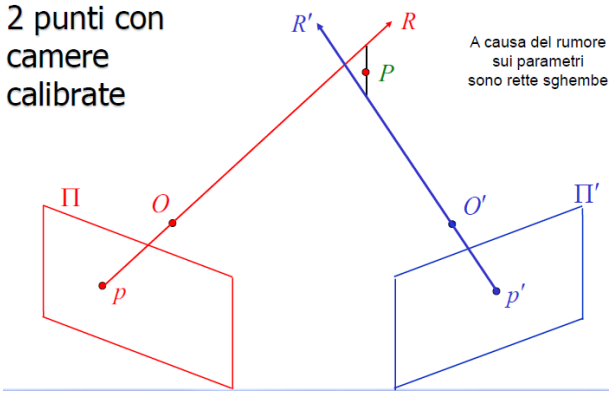
Per trovare E, è possibile cercare una matrice che minimizza l'errore epipolare tra i punti corrispondenti (noti):

$$min_E \sum_{j=1}^{n} \mathbf{x}_2^{jT} E \mathbf{x}_1^j$$

6.2 Ricostruzione tridimensionale

$\begin{pmatrix} u \\ v \end{pmatrix} = KR(\vec{x} - \vec{t})$ => $\vec{x} = \lambda (KR)^{-1} \begin{pmatrix} u \\ v \end{pmatrix} + \vec{t}$ Un punto in immagine diventa una retta in R^3.

Triangolazione stereo "sparso" se abbiamo due punti omologhi, e da essi costruiamo due rette, tali rette possono non incontrarsi a causa del rumore nei parametri di calibrazione delle camere.



Estendiamo al caso in cui abbiamo **n** immagini:

- per ogni immagine i-esima, abbiamo un'equazione tipo : $\vec{x}_i = \lambda_i (KR)^{-1} \begin{pmatrix} u \\ v \end{pmatrix} + \vec{t}$, per n immagini abbiamo :
  - n : equazioni
  - 3 + n incognite : le coordinate del punto e per ogni equazione, la variabile incognita λ_i

Per trovare la soluzione possiamo:

- Minimizzare la distanza tra la soluzione e le rette : forward projection o DLT (direct linear transfer).
- Minimizzare in coordinate immagine: minimizzare la distanza tra la projezione della soluzione nelle diverse immagini, ed il punto $p = (u_i, v_i)$ noto nell'immagine i-esima. (complesso, non lineare, reprojection).

Gli attori in gioco nel problema sono:

- P_i matrice proiettiva della camera i-esima
- p_i punto in coordinate immagine, nella camera i-esima
- $\vec{x}$ punto incognita nello spazio R^3

6.2.1 DLT Triangolazione lineare

Cerco la coordinata $\vec{x}$ che minimizza:

$$\hat{x} = min_x(\|P_1 x - p_1\| + \|P_2 x - p_2\|)$$

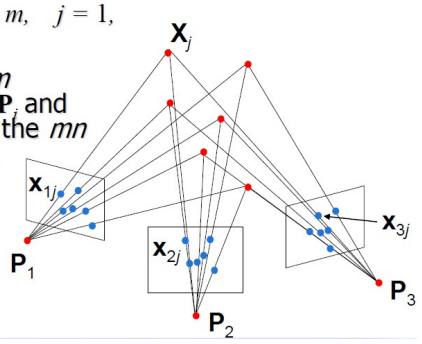
In quanto a causa di errore nei parametri di calibrazione:

$p_1 = P_1 * x + \epsilon_1$ e $p_2 = P_2 * x + \epsilon_2$

6.2.2 Structure from Motion (SfM)

Conosco la calibrazione della camera (quindi conosco **K**), ma non so dove è nel mondo. Tra due immagini successive non so quale è stato lo spostamento in R ed in $\vec{t}$.

- Given: *m* images of *n* fixed 3D points
- $\mathbf{x}_{ij} = \mathbf{P}_i \mathbf{X}_j$, $i = 1, \ldots, m$, $j = 1, \ldots, n$
- Problem: estimate *m* projection matrices $\mathbf{P}_i$ and *n* 3D points $\mathbf{X}_j$ from the *mn* correspondences $\mathbf{x}_{ij}$



- Una volta messi in corrispondenza i punti, R e t possono essere ricavati dalla matrice essenziale.
- **t** è noto a meno di un fattore moltiplicativo. Non è quindi nota la distanza tra due pin-hole, ma solo il loro reciproco rapporto.
- Di conseguenza tutto il mondo è noto a meno di un fattore moltiplicativo.

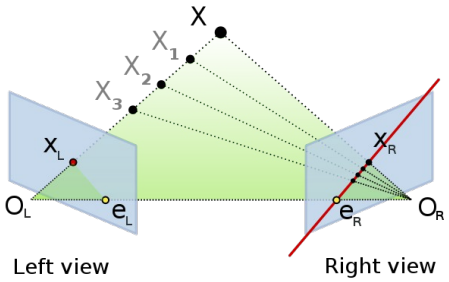
7 20180321 – Slide 07 – Free Space, Occupancy Grid, Stixel

7.1 Free Space estimation

7.1.1 V-Disparity

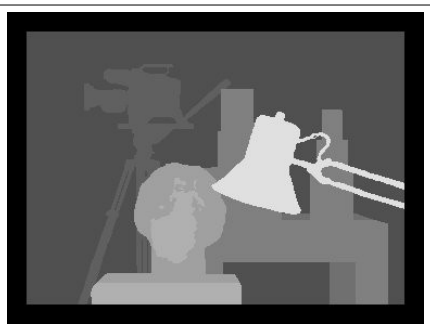
First step: compute the disparity image.

7.1.1.1 Disparity image:



Dato un punto X, proiettato nelle immagini Left e Right, nei punti corrispondenti X_L e X_R, la disparità è la distanza, in coordinate immagine, tra i punti X_L e X_R.





Ripetendo questo processo per tutti i punti dell'immagine, la mappa di disparità è un'immagine in cui ad ogni punto viene associata la disparità. Tale mappa può avere dei punti in cui non si ha nessun valore perchè in alcuni punti non si è trovata una corrispondenza tra immagine Left e Right. Nella mappa di disparità, i punti più chiari sono quelli più vicini all'osservatore.

7.1.1.2 V-Disparity

The V-disparity image: Each row of the V-disparity image is a histogram of the various values of disparity that appeared on that row in the disparity map. When done right, the disparities of the points on the ground plane will appear as a strong line in the V-disparity map.

7.1.2 Occupancy Grid mapping

A 2D array grid that models the occupancy evidence of the environment.

Each cell is either free or occupied space.

8 20180409 – Slide 08 – Bag of Words Localization

Localizzazione sulla mappa. La localizzazione sulla mappa permette di portare a termine compiti, eseguire path planning. Localizzazione serve per local behavior e long term planning.

8.1 Bag or Words

- uso SIFT o BRIEF per estrarre una serie di local features da immagini
  - In SIFT ogni punto è associato ad un descrittore di 128 dimensioni.
  - In BRIEF
  - Con tale rappresentazione dovrei gestire un dizionario di parole di 128 dimensioni, per il SIFT.
- Successivamente cerco di dividere lo spazio in sottospazi più piccoli: descrittori vicini appartengono allo stesso oggetto. Raggruppo con k-means. Salvo un vettore di numeri notevoli da 0 a N. Gli insiemi in cui divido lo spazio possono essere noti a priori considerando il corpus di dati.
- In ogni immagine registro le frequenze con cui occorrono le diverse parole. Dalle frequenze ricavo istogrammi.

Come per i testi, anche le immagini vengono trasformate in un insieme di frequenze in cui occorrono le diverse parole.

Per confrontare le immagini (come i testi) posso eseguire il prodotto scalare normalizzato tra le frequenze dei due testi.

Inverted file index: per ogni word mi segno i fotogrammi in cui essa occorre (es in quali immagini appare un cartello stradale), per poi non diver scorrere tutto il film per ritrovarlo.

Nel trattamento testi esiste TF-IDF weighting.

$$t_i = \frac{n_{id}}{n_d} * \log\left(\frac{N}{n_i}\right)$$

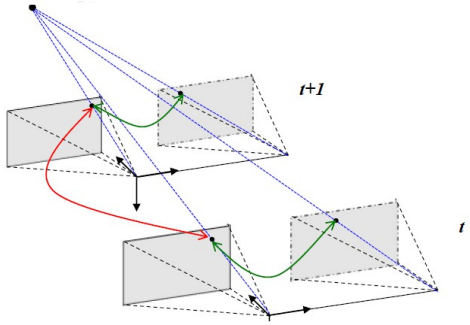
- n_{id} number of occurences of the word i-th in the document
- n_d number of words in the document
- N number of words in the database
- n_i number of occurrences of the word i-th in the database

Una parola è importante se: è poco frequente nel database, ma molto frequente nel documento analizzato.

Si noti che in Bag-of words, gli aspetti spaziali vengono persi: contano solo le occorrenze delle parole nelle immagini.

Posso passare dalle parole visuali alle frasi visuali, salvando le frequenza correlata tra le immagini, al prezzo di un aumento della mole di dati da trattare.

9 20180418 – Laboratorio su Visual Odometry



Si ricerca la corrispondenza tra punti nell'immagine sinistra e destra.

Inoltre, si cerca la corrispondenza tra i punti dell'immagine, ad esempio sinistra, tra l'istante t e l'istante t+1.

L'ipotesi è che i punti osservati siano fermi tra un'immagine e l'altra.

Uno stesso punto viene osservato nel sistema di riferimento immagine i+1 nel sistema di riferimento immagine i.

$$p_{i+1} = R * p_i + t$$

Il movimento apparente è causato dal movimento della camera.

- t è la traslazione occorsa tra i due sistemi di riferimento: la posizione del precedente sistema di riferimento camera vista dal nuovo sistema di riferimento;
- R esprime i versori del precedente sistema di riferimento nel nuovo sistema di riferimento.

Vogliamo esprimere un punto al passo i+1 sulla base del punto al passo 0.

- R_i la rotazione per convertire il punto 0 nel punto i-esimo
- t_i la traslazione per convertire il punto 0 nel punto i-esimo

quindi : $x_i = R_i * x_0 + t_i$

$\tilde{R}_i$ $\tilde{t}_i$ la rotazione e traslazione osservate al passo i-esimo. Come aggiornare R_i e t_i tra il passo i e il passo i+1?

$$x_1 = \tilde{R}_0 * x_0 + \tilde{t}_0$$
$$x_2 = \tilde{R}_1 * x_1 + \tilde{t}_1 \rightarrow x_2 = \tilde{R}_1 * \tilde{R}_0 + \tilde{R}_1 * \tilde{t}_0 + \tilde{t}_1$$

$$x_{i+1} = \tilde{R}_i * x_i + \tilde{t}_i \rightarrow x_{i+1} = \tilde{R}_i * (R_i * x_0 + t_i) + \tilde{t}_i = \tilde{R}_i * R_i * x_0 + \tilde{R}_i * t_i + \tilde{t}_i$$
$$R_{i+1} = \tilde{R}_i * R_i$$
$$t_{i+1} = \tilde{R}_i * t_i + \tilde{t}_i$$

Vogliamo esprimere un punto al passo 0 sulla base del punto al passo i-esimo.

Quindi ora: $x_0 = R_i * x_i + t_i$

$\tilde{R}_i$ $\tilde{t}_i$ la rotazione e traslazione osservate al passo i-esimo $x_{i+1} = \tilde{R}_i * x_i + \tilde{t}_i \rightarrow x_i = \tilde{R}_i^T * x_{i+1} - R_i^T * \tilde{t}_i$

$$x_0 = R_i * x_i + t_i$$
$$x_i = \tilde{R}_i^T * x_{i+1} - R_i^T * \tilde{t}_i \rightarrow x_0 = R_i * (\tilde{R}_i^T * x_{i+1} - R_i^T * \tilde{t}_i) + t_i \rightarrow x_0 = R_i * \tilde{R}_i^T * x_{i+1} - R_i * R_i^T * \tilde{t}_i + t_i$$

$x_0 = \tilde{R}_i^T * x_1 - R_i^T * t_0$ quindi al primo passo : $R_1 = \tilde{R}_i^T$ e $t_1 = -R_i^T * t_0$

Mentre per passare dal passo i-esimo al passo (i+1) esimo R e t vengono aggiornate come di sequito:

$$R_{i+1} = R_i * \tilde{R}_i^T$$
$$t_{i+1} = t_i - R_i * \tilde{R}_i * \tilde{t}_i$$

10 Link

10.1 Corsi

- http://www.cs.toronto.edu/~urtasun/courses/CSC2541/CSC2541_Winter16.html Urtasun